

法律文档脱敏工具

首次使用指南

完全本地运行 | 不联网不上传 | 支持 30+ 种敏感信息自动识别

适用于 macOS / Windows / Linux

by 黄灵宝同学

目录

- 一、产品简介
- 二、安装准备
- 三、快速启动（推荐）
- 四、首次启动选项：是否处理英文文书
- 五、手动安装（备选）
- 六、使用方法 - 网页界面
- 七、检测层级介绍：规则 + 中文 NER + 英文 LLM
- 八、OCR 引擎：RapidOCR / PaddleOCR
- 九、输出格式：MD / DOCX / PDF
- 十、使用方法 - 命令行
- 十一、支持的敏感信息类型
- 十二、常见问题解答
- 十三、隐私安全说明

一、产品简介

法律文档脱敏工具是一款完全本地运行的敏感信息脱敏软件，专为法律工作者设计。它能自动识别并替换文档中的个人信息、公司名称、案号、金额、地址等
30
余种敏感数据，确保文件在分享、归档或公开时不泄露隐私。

核心特点

- 完全离线 - 所有处理在本地完成，不调用任何外部 API，不上传任何数据
- 多格式输入 - 支持 PDF（含扫描版 OCR）、Word（DOCX/DOC）、TXT、Markdown、图片
- 多格式输出 - 一次脱敏同时生成 MD / DOCX / PDF 三份文件，按需选择
- 原格式保留 - DOCX→DOCX 完整保留字体/字号/页眉页脚；PDF→PDF 原地脱敏保留布局/盖章
- 三层检测 - 正则规则 + 中文 NER（CLUENER）+ 英文 LLM（OpenAI privacy-filter，可选）
- 智能识别 - 自动检测 30+
种敏感信息：人名（含复姓）、公司、身份证、手机、银行卡、案号、地址等
- 双 OCR 引擎 - 默认 RapidOCR（快、轻量）；复杂排版可切 PaddleOCR（准、慢）
- 灵活策略 - 占位符替换（[PERSON_1]）/ 部分掩码（138****5678）两种模式
- 冲突仲裁 - 规则与 LLM 结果重叠时按 5 条规则智能仲裁，互相纠错
- 同名扩展 - 同一姓名在文档中所有出现位置自动一致脱敏
- 自定义词典 - 可手动添加/排除敏感词，适配特定文档需求

二、安装准备

系统要求

项目	要求
操作系统	macOS 10.15+ / Windows 10+ / Linux
Python	Python 3.9 或以上版本（推荐 3.11）
磁盘空间	基础约 1.5GB（含 PyTorch + venv）；加中文 NER 模型 +400MB；加英文模型 +2.6GB
内存	建议 8GB 以上（加载 LLM 模型时占用约 3-4GB）
浏览器	Chrome / Edge / Safari / Firefox（任选）
网络	首次启动需联网下载依赖和模型，之后完全离线运行

检查 Python 是否已安装

macOS: 按 Command + 空格，搜索"终端"，打开后输入：

```
python3 --version
```

Windows: 按 Win + R，输入 cmd 回车，然后输入：

```
python --version
```

如果显示 Python 3.x.x（如 Python 3.11.3），说明已安装。如果提示"未找到命令"，请从 python.org 下载安装。

注意: Windows 安装 Python 时务必勾选 "Add Python to PATH"（安装界面最下方的复选框），否则在命令行中无法使用 python 命令。

三、快速启动（推荐）

这是最简单的启动方式，仅需两步：解压 + 双击。

macOS 用户

1

解压文件

将下载的 legal-anonymizer.zip 解压到任意位置（如桌面）

2

双击启动

双击文件夹中的【请双击我！】启动脱敏工具.command。首次运行会自动安装依赖，完成后会自动打开浏览器。

注意: 首次打开可能弹出 macOS 安全提示"无法验证开发者"。请打开系统设置 > 隐私与安全性，向下滚动找到被阻止的提示，点击"仍要打开"，输入密码确认即可。之后再次双击就不会再弹提示。

Windows 用户

1

解压文件

右键 legal-anonymizer.zip，选择"全部解压缩"

2

双击启动

双击文件夹中的启动脱敏工具.bat

四、首次启动选项：是否处理英文文书

首次双击启动脚本时，工具会询问您一个问题：

说明："您是否经常处理英文/涉外法律文书？(y / n)"

这是为了决定是否启用英文识别能力（基于 `OpenAI` `privacy-filter` 模型）。工具默认能识别中文文档里的所有敏感信息，英文识别只对涉外律师有用。

选择 "y"（是）—— 启用英文识别

- 能识别英文人名（如 John Smith）、英文地址、国际电话、API 密钥
- 首次勾选 `OpenAI` 开关时会下载约 2.6 GB 模型（一次性）
- 适合涉外仲裁、跨境合同、外资企业法律事务

选择 "n"（否）—— 仅中文模式

- 只识别中文 PII，但中文文档准确率已接近 100%
- 节省 2.6 GB 磁盘空间和首次下载时间
- 适合绝大多数中国律师场景（合同/判决书/答辩状均纯中文）
- 网页界面将不显示 `OpenAI` 开关

TIP: 选错了想反悔？删除项目根目录下的 `.user_config` 文件，重新双击启动脚本即可重新选择。

五、手动安装（备选）

如果快速启动不生效，可以手动安装。

1 打开终端/命令行

macOS: Command + 空格 > 搜索"终端"

Windows: Win + R > 输入 cmd > 回车

2 进入项目文件夹

在终端输入 cd ，然后将文件夹从访达/资源管理器拖到终端窗口，按回车。

或直接输入路径，例如：cd ~/Desktop/legal-anonymizer

3 安装依赖（仅首次）

macOS: pip3 install -r requirements.txt

Windows: pip install -r requirements.txt

等待安装完成，无红色报错即可。

4 启动工具

macOS: python3 web_app.py

Windows: python web_app.py

启动后会自动打开浏览器。如未自动打开，手动访问终端显示的地址（通常是 http://127.0.0.1:8080）

重要: 不要关闭终端窗口！关闭终端 = 停止服务。使用完毕后再关闭。

六、使用方法 - 网页界面

基本流程

1

上传文件

将文件拖拽到网页上传区域，或点击选择文件。支持 PDF、DOCX、TXT 格式。
也可以将文件放入项目文件夹下的 inbox 目录，在页面中直接选择。

2

自动分析

上传后工具会自动扫描文档，列出所有识别到的敏感信息。每项旁边有复选框，可以取消勾选不需要脱敏的项目。

3

手动补充（可选）

如果发现有遗漏的敏感信息，可以手动添加到自定义词典。词典会持久保存，下次使用时自动生效。

4

执行脱敏

点击"执行脱敏"按钮，等待处理完成后下载脱敏结果文件。
同时会生成映射表（JSON），记录每个占位符对应的原始内容。

脱敏策略说明

策略	效果示例	适用场景
占位符替换	张三 > [PERSON_1]	完全隐藏原始信息，适合公开发布
部分掩码	138****5678	保留部分信息便于核对，适合内部使用

继续脱敏功能

第一次脱敏后，如果发现仍有遗漏的敏感信息，可以使用"继续脱敏"功能：手动添加遗漏的词条，工具会基于原始文本重新处理，新添加的词条也会自动存入词典供后续使用。

七、检测层级介绍：规则 + 中文 NER + 英文 LLM

本工具采用三层检测架构，每层负责不同类型的敏感信息，协同工作互相纠错。这是它准确率高的核心原因。

层级	负责检测	速度
正则规则	身份证、手机、邮箱、案号、信用代码等 30+ 结构化数据	极快（毫秒级）
中文 NER（CLUENER）	中文人名（含复姓）、公司名、律所、地址、机构	快（秒级）
英文 LLM（OpenAI，可选）	英文人名、英文地址、国际电话、API 密钥	稍慢（数秒）

网页界面的检测层开关

在网页上传区域下方有两个（或三个）开关：

- 启用 OCR——扫描版 PDF / 图片必开；非扫描 PDF 可选
- 中文 NER——所有中文文书都建议开启，能补正则的盲区
- OpenAI privacy-filter——仅在首次启动选择"是"时显示，处理英文文书时勾选

八、OCR 引擎：RapidOCR / PaddleOCR

当输入是扫描版 PDF 或图片时，工具会用 OCR 引擎把图像转为文字。内置两个引擎：

引擎	速度（每页）	准确度	体积	默认
RapidOCR	约 2 秒	良好	15 MB	
PaddleOCR 3.5	约 30 秒	稍优（复杂排版）	约 200 MB	

TIP: 什么时候切到 PaddleOCR ? RapidOCR

默认情况下识别得已经很好。如果你发现某份扫描版 PDF 错字特别多（比如盖章、糊字、表格复杂），勾选 OCR 后再勾"PaddleOCR"重新分析一次。

九、输出格式：MD / DOCX / PDF

工具支持同时输出三种格式。在网页脱敏页面，“输出格式”那里有三个复选框，可以全选，也可以只勾你需要的。

格式	保留原格式	适用场景
MD (Markdown)	×	快速预览、复制粘贴、导入笔记软件
DOCX (Word)	输入 DOCX 时完整保留字体/字号/排版	律师工作底稿、案件归档、给客户
PDF	输入 PDF 时原地脱敏，保留布局/盖章/签名	正式文件、法庭证据、对外交付

原格式保留是什么意思？—— 比如你输入一份 Word 合同（标楷体小四 1.5 倍行距），输出的 DOCX 文件还是标楷体小四 1.5 倍行距，只是当事人姓名变成了占位符。同理 PDF 输入会得到一份保留所有布局/字体/盖章的脱敏版 PDF。

说明: 跨格式输出（如 PDF→DOCX）：会用仿宋小四 1.5 倍行距（法律文书标准模板）重新排版。

十、使用方法 - 命令行

命令行适合批量处理或集成到工作流中。

脱敏 Word 文档（保留原格式）：

```
python3 cli.py anonymize input.docx -o output.docx --cn-llm
```

脱敏 PDF（PDF 原地脱敏）：

```
python3 cli.py anonymize input.pdf -o output.pdf --cn-llm
```

一次输出 MD+DOCX+PDF 三种格式：

```
python3 cli.py anonymize input.pdf -o output -f md,docx,pdf --cn-llm
```

扫描版 PDF（启用 OCR + 中文 NER）：

```
python3 cli.py anonymize scan.pdf -o output.docx --ocr --cn-llm
```

扫描版用 PaddleOCR 引擎：

```
python3 cli.py anonymize scan.pdf -o out.docx --ocr --ocr-engine paddleocr
```

全开模式（中英混合涉外案件）：

```
python3 cli.py anonymize input.pdf -o out.pdf --cn-llm --llm
```

只分析不脱敏：

```
python3 cli.py analyze input.docx --cn-llm
```

查看所有支持的类型：

```
python3 cli.py list-types
```

只脱敏手机号和邮箱：

```
python3 cli.py anonymize input.pdf --only phone,email
```

使用部分掩码策略：

```
python3 cli.py anonymize input.pdf --mask-strategy partial
```

十一、支持的敏感信息类型

工具支持自动识别以下 30+ 种敏感信息：

类别	包含类型
身份证件	身份证号、护照号、港澳通行证、台湾通行证、军官证
企业/机构	统一社会信用代码、组织机构代码、税务登记号、公司名、律所名
案件/合同	案号、合同编号、发票号码、文件编号
联系方式	手机号、座机/传真、400/800 电话、邮箱、网址
社交账号	QQ 号、微信号
金融信息	银行卡号、人民币金额（含中文大写）、外币金额
车辆信息	车牌号、车辆识别码（VIN）
地址信息	完整地址、邮政编码、门牌号
人名	基于上下文关键词自动识别法律文书中的人名
机构名称	公司、律所、法院、政府机构、银行、学校、医院等
日期时间	日期、时间、日期时间
网络标识	IP 地址、MAC 地址
证书编号	房地产证号、证书/批文编号、专利/商标编号
项目名称	项目、工程、系统、平台名称

十二、常见问题解答

Q: pip install 报错 Permission denied

A: 在命令前加 --user : pip3 install --user -r requirements.txt

Q: 启动后浏览器没有自动打开

A: 手动打开浏览器，输入终端中显示的地址（通常是 <http://127.0.0.1:8080>）。

Q: 启动报错 Address already in use

A: 端口被占用，程序会自动尝试 8080-8099 端口。如果都被占用，关掉其他程序后重试。

Q: Windows 上 python 命令打开 Microsoft Store

A: 在系统设置中关闭"应用执行别名"中的 Python 项，或使用完整路径运行。

Q: macOS 提示 command not found: python3

A: 需要安装 Python。或尝试安装 Xcode 命令行工具：xcode-select --install

Q: 报错 ModuleNotFoundError

A: 依赖未安装成功，重新执行 pip 安装命令。确保 pip 和 python 版本一致：python3 -m pip install -r requirements.txt

Q: 我之前选了不安装英文模型，现在想用了怎么办

A: 删除项目根目录下的 .user_config 文件，重新双击启动脚本，会再次询问。选择"y"即启用英文识别。

Q: 国内下载模型很慢

A: 启动脚本默认走 hf-mirror.com 国内镜像。如果还慢，可以手动设置环境变量：export HF_ENDPOINT=https://hf-mirror.com

Q: 勾选"中文 NER"后第一次分析等了很久

A: 正常现象。首次启用会从 HuggingFace 下载约 400MB 模型，国内 1-3 分钟。下完后所有后续操作都是秒级。

Q: 网页里没有 OpenAI 开关

A: 说明你首次启动时选择了"仅中文模式"。删除 .user_config 重启即可重新选择。

Q: DOCX 输出格式和原文不一样

A: 当输入是 DOCX 且输出也是 DOCX 时，工具会自动保留原始格式。如果输入是 PDF，输出的 DOCX 用仿宋小四 1.5 倍行距标准模板。

Q: PDF 输出和原 PDF 长得一样

A: 当输入是 PDF 且输出也是 PDF 时，会做"原地脱敏"——保留原 PDF 的字体、布局、盖章、签名，只把敏感字替换为占位符。

Q: OCR 识别错字多

A: 默认 RapidOCR 已经够用。复杂排版可在勾选"启用 OCR"后切换到"PaddleOCR"引擎重新分析（更慢但稍准）。

Q: 扫描版 PDF 识别不了文字

A: 勾选"启用 OCR"开关。RapidOCR 引擎已内置，无需额外安装。首次使用会自动下载约 15MB 模型。

Q: 某些敏感信息没有被识别到

A: 一是开启"中文 NER"层（强烈建议）；二是用网页"用户词典"功能手动添加，词典会持久保存。

Q: 脱敏后想反向查回原文

A: 每次脱敏会生成一份 _mapping.json 映射表，包含占位符与原文的对应关系。请像对待原文件一样妥善保管。

十三、隐私安全说明

TIP: 本工具所有处理完全在本地进行，不调用任何外部 API，不上传任何数据到云端。
。代码完全开源可审计，适合处理高度机密的法律文件。

- 所有文本分析和替换在内存中完成，不经过网络传输
- 所有 AI 模型（中文 NER / OpenAI / RapidOCR / PaddleOCR）首次下载后完全离线运行，不需要联网
- 上传的文件会在处理完成后自动清理（网页模式下 24 小时后删除）
- 生成的映射表（_mapping.json）包含原始敏感信息与占位符的对应关系，请妥善保管
- 建议在处理完成后删除映射文件，或将其存放在安全的位置

- 工具源码完全开源可审计，可执行 `grep -r "requests|urllib|http" *.py` 验证项目代码本身零网络调用
- 可设置三个环境变量进一步彻底断网：`HF_HUB_OFFLINE=1`、`TRANSFORMERS_OFFLINE=1`、`PADDLE_PDX_DISABLE_MODEL_SOURCE_CHECK=1`

重要: 映射表安全提示：脱敏后生成的 `_mapping.json` 文件包含所有原始敏感信息的对应关系。请像对待原文件一样妥善保管此文件，不要随脱敏版文件一起分享。

如有问题或建议，欢迎反馈。祝使用愉快！

Made with love by 黄灵宝同学